

$$V(k_0) = \sum_{t=0}^{\infty} [\beta^t \ln(1 - \alpha\beta) + \beta^t \alpha \ln k_t]$$

$$= \frac{\alpha}{1 - \alpha\beta} \ln(1 - \alpha\beta) \sum_{t=0}^{\infty} \beta^t + \alpha \sum_{t=0}^{\infty} \beta^t \left[ \frac{1 - (\alpha\beta)^t}{1 - \alpha\beta} \ln \alpha\beta + \alpha^t \ln k_0 \right]$$

$$= \frac{\alpha}{1 - \alpha\beta} \ln(1 - \alpha\beta) \ln(\alpha\beta) \sum_{t=0}^{\infty} \left[ \frac{\beta^t}{1 - \alpha} - \frac{(\alpha\beta)^t}{1 - \alpha} \right]$$

$$= \frac{\alpha}{1 - \alpha\beta} \ln k_0 + \frac{\ln(1 - \alpha\beta)}{1 - \beta} + \frac{\alpha\beta}{(1 - \beta)(1 - \alpha\beta)} \ln(\alpha\beta)$$

$$\begin{aligned} \text{左边} = V(k) &= \frac{\alpha}{1 - \alpha\beta} \ln k + \frac{\ln(1 - \alpha\beta)}{1 - \beta} + \frac{\alpha\beta}{(1 - \beta)(1 - \alpha\beta)} \ln(\alpha\beta) \\ &\triangleq \frac{\alpha}{1 - \alpha\beta} \ln k + A \end{aligned}$$

$$\text{右边} = \max \{ u(f(k) - y) + \beta V(y) \}$$

利用 FOC 和包络条件求解得到  $y = \beta k^\alpha$ , 代入求右边。

Institute for Advanced Study

$$\text{右边} = \max \{ u(f(k) - y) + \beta V(y) \}$$

$$= u(f(k) - g(k)) + \beta \left[ \frac{\alpha}{1 - \alpha\beta} \ln g(k) + A \right]$$

$$= \ln(k^\alpha - \alpha\beta k^\alpha) + \beta \left[ \frac{\alpha}{1 - \alpha\beta} \ln \alpha\beta k^\alpha + A \right]$$

$$= \ln(1 - \alpha\beta) + \alpha \ln k + \beta \left[ \frac{\alpha}{1 - \alpha\beta} [\ln \alpha\beta + \alpha \ln k] + A \right]$$

$$= \alpha \ln k + \frac{\alpha\beta}{1 - \alpha\beta} \alpha \ln k + \ln(1 - \alpha\beta) + \frac{\alpha\beta}{1 - \alpha\beta} \ln \alpha\beta + \beta A$$

$$= \frac{\alpha}{1 - \alpha\beta} \ln k + \ln(1 - \alpha\beta) + \frac{\alpha\beta}{1 - \alpha\beta} \ln \alpha\beta + \beta A$$

$$= \frac{\alpha}{1 - \alpha\beta} \ln k + (1 - \beta)A + \beta A$$

$$= \frac{\alpha}{1 - \alpha\beta} \ln k + A$$

整理: Jianpeng & QI

整理时间: November 3, 2018

Email: jianpengqi@126.com

所以, 左边 = 右边, 证毕。

# 目 录



1	推荐算法	3
1.0.1	NMF . . . . .	3

# 第 1 章

## 推荐算法



### 1.0.1 NMF

NMF(Non-negative matrix factorization) [1], 直译为非负矩阵分解, 主要用于分解矩阵, 缺失数据的预测等。矩阵分解有很多相关的研究, 可以用于加快计算结果, 以及表示缺失的数据等。在推荐系统中, 缺失值处理是获取推荐物品较为关键的一步, 比如电影推荐, 往往推荐的都是未看过/评分过的电影。如何计算缺失值, 有很多方法。



**Note:** *Todo:* 缺失值计算方法学习

NMF 在分解矩阵的同时, 对缺失值也进行了处理, 考虑一个  $n * m$  的矩阵  $V$ , 我们想要将这个矩阵使用 NMF 的方法进行分解, 获取缺失值等操作, 可以利用如下公式:

$$V_{i\mu} \approx (WH)_{i\mu} = \sum_{a=1}^r W_{ia} H_{a\mu}$$

其中包含  $r$  列的  $W$  表示基 (原文中为 basis images) 矩阵。  $H$  表示编码 (encoding) 矩阵,  $H$  中每一列与原矩阵  $W$  中的每一列对应。组合在一起的含义就是  $H$  中的一列应用  $W$  中的一个编码方式可以获得原矩阵中对应位置的数值 (近似值)。NMF 矩阵分解满足的约束为  $(n + m) * r < nm$  (很明显, 分解后矩阵数据量变少了)。

原文描述如下:



**Ref:** The  $r$  columns of  $W$  are called basis images. Each column of  $H$  is called an encoding and is in one-to-one correspondence with a face in  $V$ . An encoding consists of the coefficients by which a face is represented with a linear combination of basis images. The dimensions of the matrix factors  $W$  and  $H$  are  $n * r$  and  $r * m$ , respectively.  $\square$

但是这个公式并没有体现出如何去计算, 我们只知道  $V$ , 其他一无所知, 唯一知道的是可以输入一个叫  $rank$  的东西来把  $V$  分解为包含  $n * r$  的  $W$  以及  $r * m$  的  $H$ 。通过公式还能猜出来, 优化的目标一定是  $WH$  无限的接近  $V$ , 也就是两者尽可能的相似。根据这个目标, 大致需要一个 cost function 来评估分解的好坏。

### 计算方式 [2]

判断两个矩阵间是否近似的方法有很多种，但是在判断的过程中我们需要加入一个衡量的标准，在这里称为 cost function。我们的目标是  $V \approx WH$ ，也就是最小化两个矩阵之间的差异，最小化两个矩阵之间的差异有很多方式，比如  $\square$ Euclidean distance:

$$\text{Minimize}(\|V - WH\|^2)$$

亦或是最小化 (Kullback-Leibler divergence):

$$D(A||B) = \sum_{ij} (A_{ij} \log \frac{A_{ij}}{B_{ij}} - A_{ij} + B_{ij})$$

这里考虑 Euclidean distance。

观察上面的公式，当只有一个变量时是很好求的，因为是凸函数 ( $f(x) = ax^2$  这种)，必然会找到最优解。但是公式中只有  $V$  是已知的，因此需要其他的方式去求解，比如梯度下降，由于多个变量的存在，我们往往找到的是局部最优解。虽然梯度下降的解法简单，但是存在一个诟病就是对步长 (step size) 非常的敏感，换言之就是步子太大有可能直接跳过去了。因此，论文的作者给了一个迭代更新的方法 (Euclidean distance):

$$H_{a\mu} \leftarrow H_{a\mu} \frac{(W^T V)_{a\mu}}{(W^T W H)_{a\mu}}$$

$$W_{ia} \leftarrow W_{ia} \frac{(V H^T)_{ia}}{(W H H^T)_{ia}}$$

我们看到，其实  $H_{a\mu}$  的下一代迭代值是乘上了一个系数  $\frac{(W^T V)_{a\mu}}{(W^T W H)_{a\mu}}$ ，这也就是原文中倍增的意思 (Multiplicative)。使用乘法来算是不明智的，因为很难复用上一次计算的结果，既浪费性能又浪费时间，那么有没有渐进式的算法呢？让人兴奋的是作者给出了渐进式的更新计算公式：

$$H_{a\mu} \leftarrow H_{a\mu} + \eta_{a\mu} [(W^T V)_{a\mu} - (W^T W H)_{a\mu}]$$

这个公式很漂亮， $H_{a\mu}$  每次加上一点就能不断的迭代下去，并且利用上了上一次计算的结果。同时，如果令  $\eta_{a\mu} = \frac{H_{a\mu}}{(W^T W H)_{a\mu}}$ ，我们就得到了倍增更新公式。

NMF 存在的一个问题是，每次计算得到的是局部最优解，所以多次运行的结果可能都不一致。



## 参考文献



- [1] Daniel D Lee and H Sebastian Seung. Learning the parts of objects by non-negative matrix factorization. *Nature*, 401(6755):788, 1999.
- [2] Daniel D. Lee and H. Sebastian Seung. Algorithms for non-negative matrix factorization. In T. K. Leen, T. G. Dietterich, and V. Tresp, editors, *Advances in Neural Information Processing Systems 13*, pages 556–562. MIT Press, 2001.